

提案：Agent Roles —— 面向多 agent 系统的可移植角色规范

过去几个月，我一直在维护一个多 agent 协作开源项目 [claude_codex_bridge](#)。在持续实践中，有一个反复出现的问题推动我拆出了一个独立的规范项目：[Agent Roles](#)。

问题是：随着 agent 配置越来越复杂，skills 很容易积累，却很难作为一个系统来管理。每新增一个 skill，它都会混入共享能力池；工具依赖逐渐模糊；每次为了特定职能启动一个 subagent，又常常需要重新写一大段临时提示词来解释同样的上下文。我们缺少一个围绕“专业 agent”的清晰包边界。

核心想法

Role 是比 skill 更高一层的单位。skill 描述的是一个可复用能力，而 Role 描述的是一个完整的专业 agent：

```
role memory + skills + tool dependencies + permission boundaries +  
host adapter metadata
```

我的设想是，Role 应该是一种静态、可移植的定义：可以从 catalog 安装，可以挂载到某个 agent host 中，也可以卸载而不污染主环境。Role 源内容不应该保存项目状态或会话历史。Host 可以根据 Role 源内容生成投影输出，但这些输出不应该再写回 Role 本身。

Role 不是新概念

ChatGPT Store 里的 Custom GPT、AI 角色扮演社区里的 character card，本质上都在指向类似需求：稳定、可复用的 agent 身份，带有特定行为、知识和交互模式。Claude Projects、Copilot instruction files 以及类似平台内 persona 系统，也都在各自产品内部处理这一类问题。

这些系统通常不需要解决的是更工程化的打包问题：跨不同 host 的可移植性、声明式工具依赖、生命周期管理（install / update / mount / unmount），以及脱离单一产品生态后的互操作性。这正是 Agent Roles 想尝试补上的空缺。

目前已有内容

这个仓库已经有一个工作中的预览版本：

- specs/role-v1.md 和 specs/metadata-v1.md 描述 Role 目录结构和 role.toml 定义格式
- npm CLI agent-roles (当前版本 0.1.1) 可以从远程 catalog 列出和安装 Roles
- 一个参考 Role：agentroles.archi，用于展示架构审查角色的具体格式

当前 v0.1 规范刻意保持保守：permissions 只是声明式建议，并不执行强制隔离；跨 host 绑定还是一个概念，而不是强制文件格式；runtime mount 和 hot reload 也暂时推迟。这个阶段的目标，是先把静态 Role 定义形状讨论清楚，再在上面增加生命周期机制。

希望获得反馈的问题

关于定义格式：目前使用 role.toml 作为 Role manifest，因为它可读、轻量，对工具要求低。但我并不执着于 TOML。如果从实际工具链角度看，其他格式会更好吗？

关于权限：role.toml 里的 [permissions] 目前是高层声明，例如 read_files = true、write_files = false、network = false。这让预览规范不需要先实现完整权限 runtime，但也意味着这些声明本身并不强制生效。对一个预览规范来说，这是合理折中，还是会让 permissions 章节显得误导？

关于范围：这个规范刻意描述可移植的 Role artifact，而不是 marketplace 或 host runtime。我希望 core format 保持 host-neutral，让不同 agent hosts 可以各自实现 adapters，而不被绑定到某一种实现。这个 framing 是否成立？还是说，没有先锚定一个具体 host，它会显得过于抽象？

关于概念本身：也许现有 plugin 系统已经能解决这个问题，或者我把问题放在了错误的抽象层。如果这个 framing 有明显缺口，我希望尽早听到反对意见。

Project: <https://github.com/SeemSeam/agent-roles-spec>

如果你正在做 agent platform、coding-agent host 或 multi-agent system，并且对这个方向有想法，包括怀疑和反对意见，我都非常希望听到。